

Применение сверточных нейронных сетей к задаче классификации трехмерных моделей

ОБУЧАЮЩИЙСЯ:

ВАКУЛИН А.А.

РУКОВОДИТЕЛИ:

КРЫЛОВЕЦКИЙ А.А.

ЧЕРНИКОВ И.С.

ВОРОНЕЖСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК
КАФЕДРА ЦИФРОВЫХ ТЕХНОЛОГИЙ

Цель:

Разработка математических методов и алгоритмов классификации трёхмерных объектов с помощью сверточных нейронных сетей

Задачи:

- Исследование возможных представлений (дескрипторов) трехмерных объектов
- Исследование технологий сверточных нейронных сетей и построение архитектуры сети для решения поставленных задач
- Создание программной реализации системы распознавания трехмерных объектов с использованием сверточных нейронных сетей

Система классификации

- Формирование базы данных
- Подготовка данных
- Построение глобальных дескрипторов поверхности
- Обучение сверточной нейронной сети

Формирование базы данных

Princeton Shape Benchmark

- 540 объектов
- 3 класса



«Самолет»



«Мебель»



«Человек»

Рис.1: Классы объектов, выбранные для распознавания

Подготовка данных

Контроль разрешения объектов




Рис. 2: Базовые операции алгоритма контроля разрешения трехмерных объектов. Ребро свернуто в точку(верхний рисунок). Ребро разделено на два(нижний рисунок)

Построение дескрипторов

Спиновые изображения




Рис. 3: Относительные координаты спинового изображения α и β

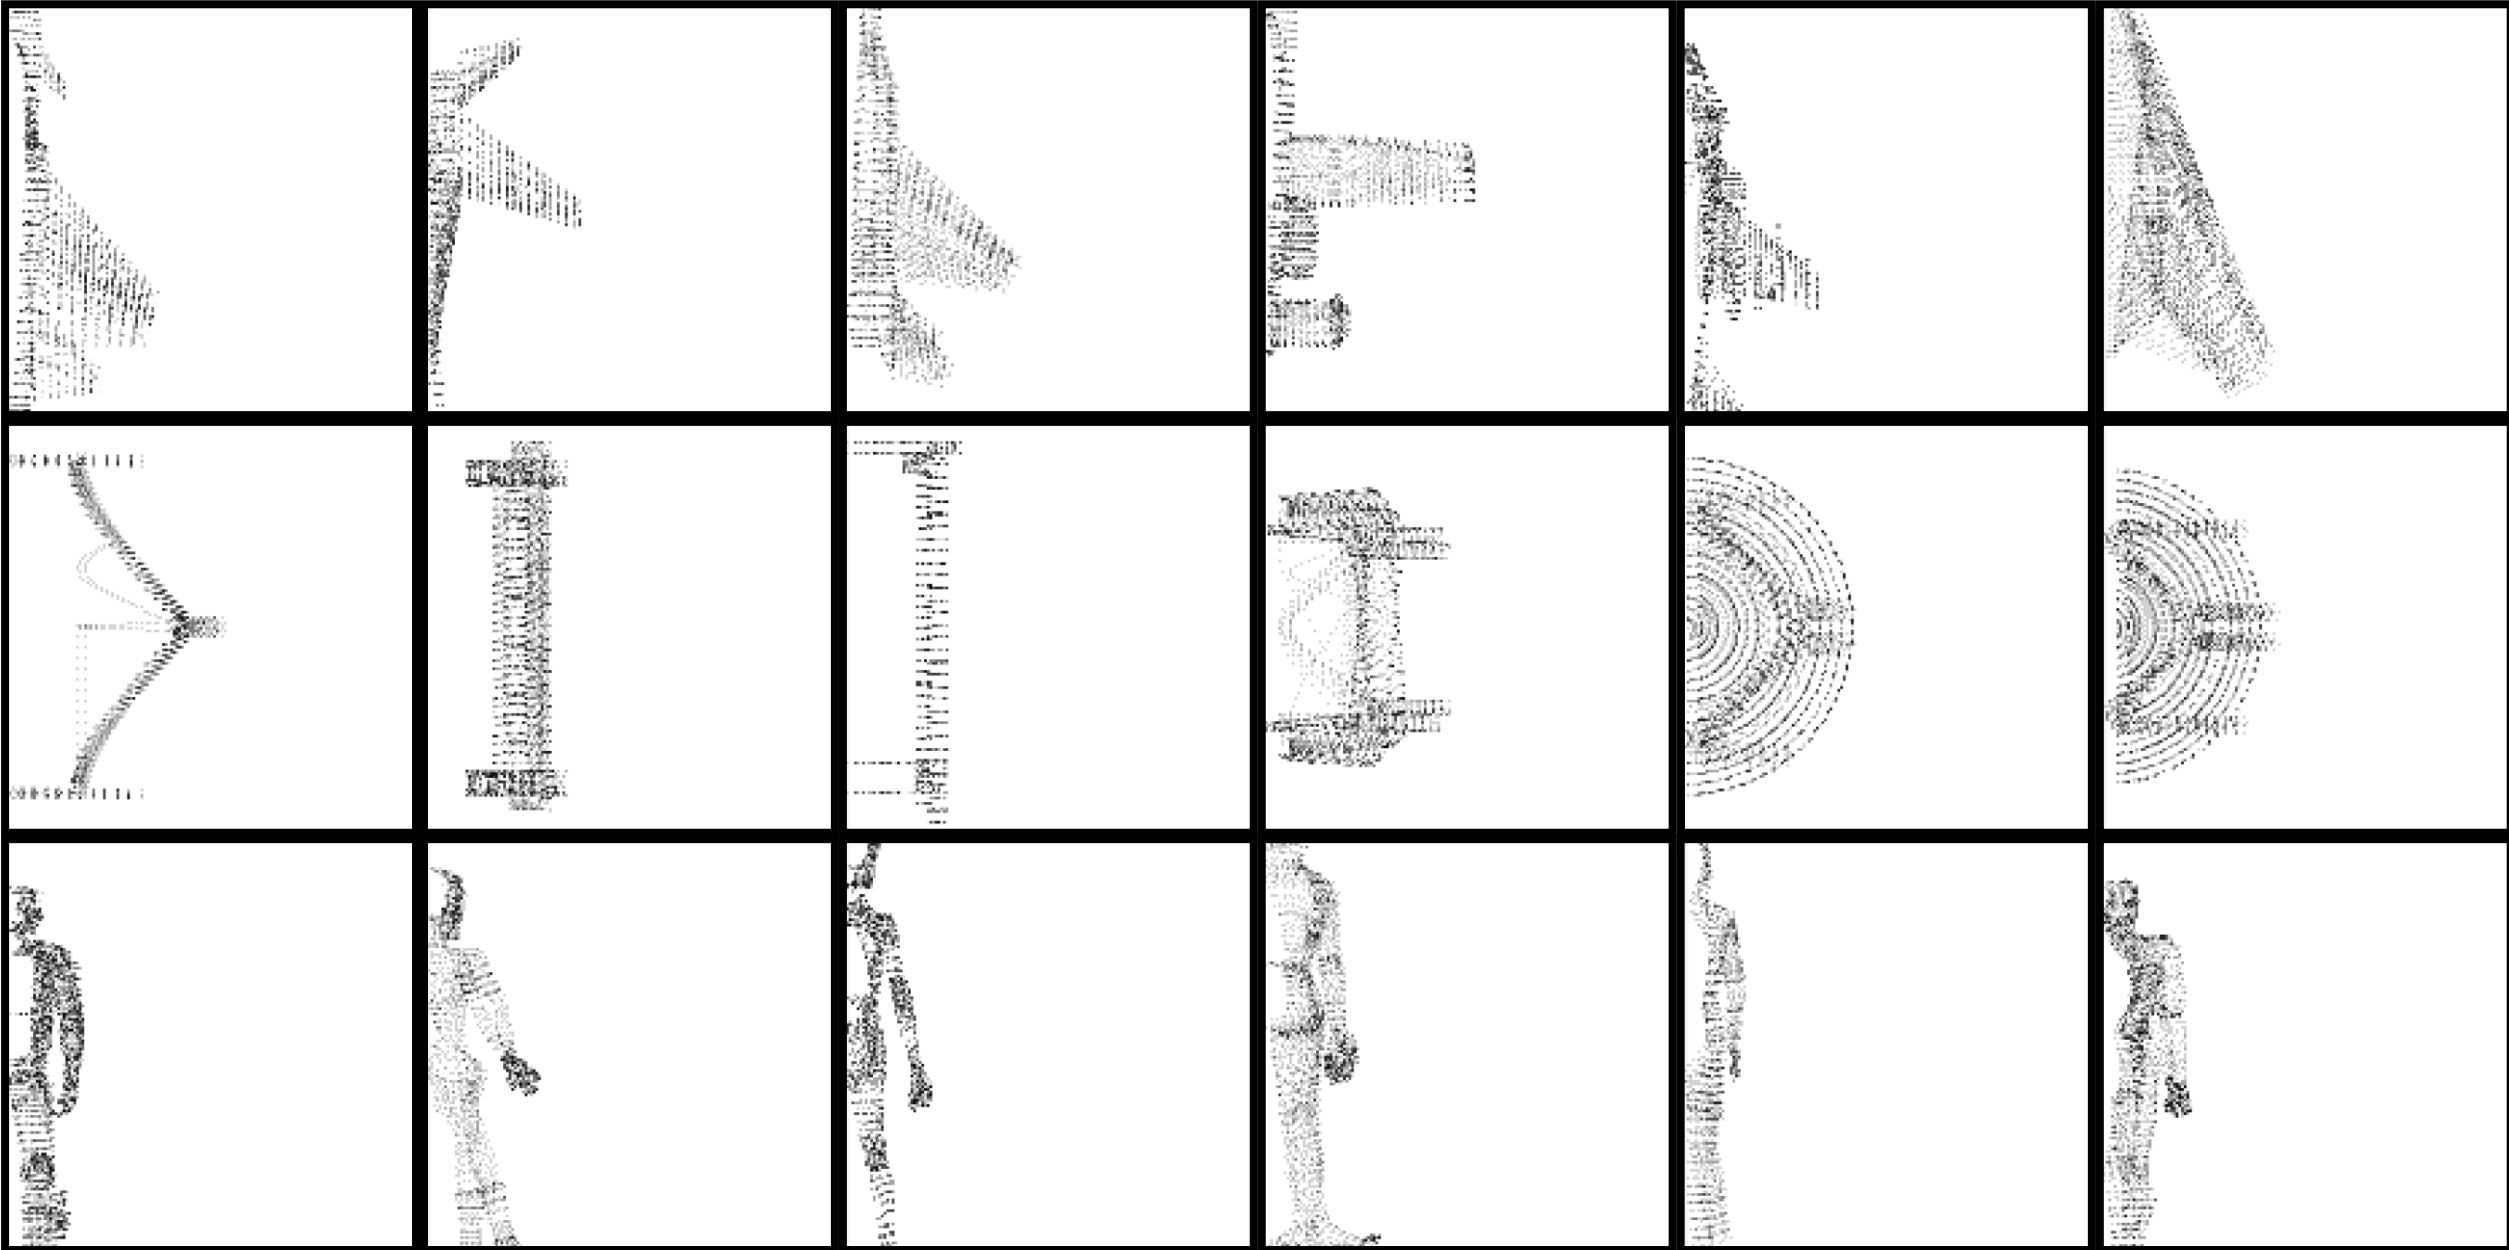


Рис. 4: Примеры спиновых изображений

Сверточная нейронная сеть

Общее представление

- Сверточный слой (convolutional)
- Слой объединения (pooling)
- Слой полносвязной нейронной сети





Рис. 5: Общая схема сверточной нейронной сети

Сверточная нейронная сеть

Сверточный слой (convolutional)



Multiplication and Summation = $(50 \cdot 30) + (50 \cdot 30) + (50 \cdot 30) + (20 \cdot 30) + (50 \cdot 30) = 6600$ (A large number!)

Рис. 6: Пример работы сверточного слоя

Сверточная нейронная сеть

Слой объединения (pooling)




Рис. 7: Пример работы слоя объединения

Реализация системы №1

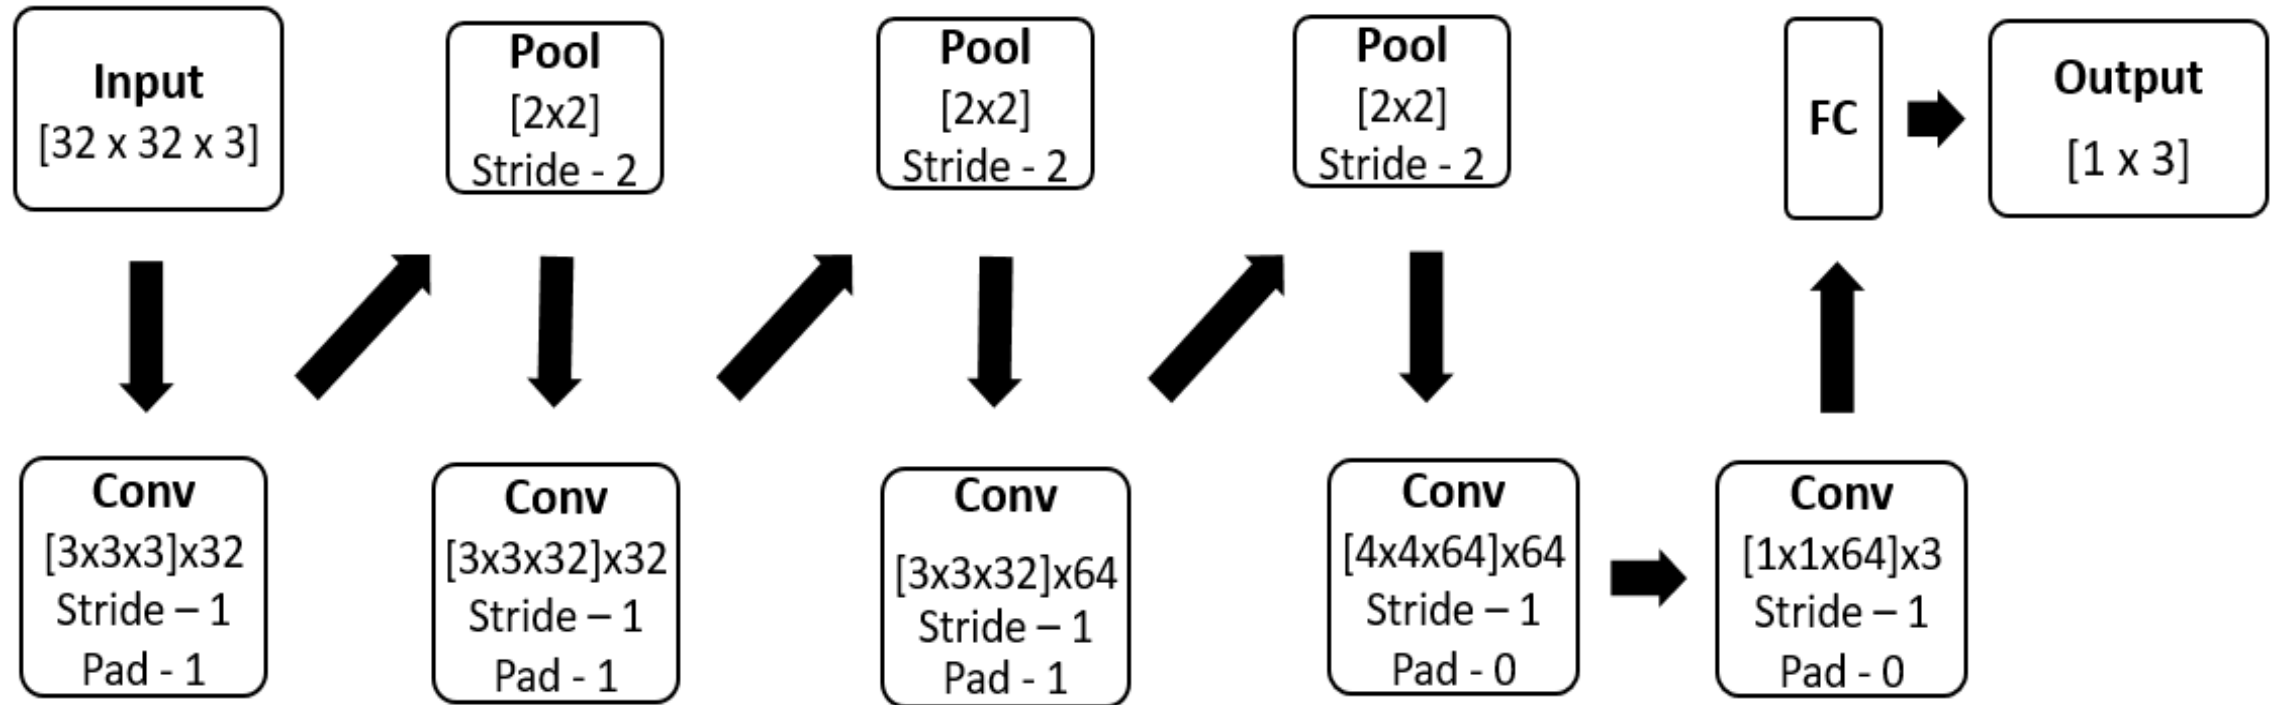



Рис. 8: Архитектура сверточной нейронной сети,
использованная для реализации системы №1

График изменения значений функции ошибки для реализации системы №1



Реализация системы №2

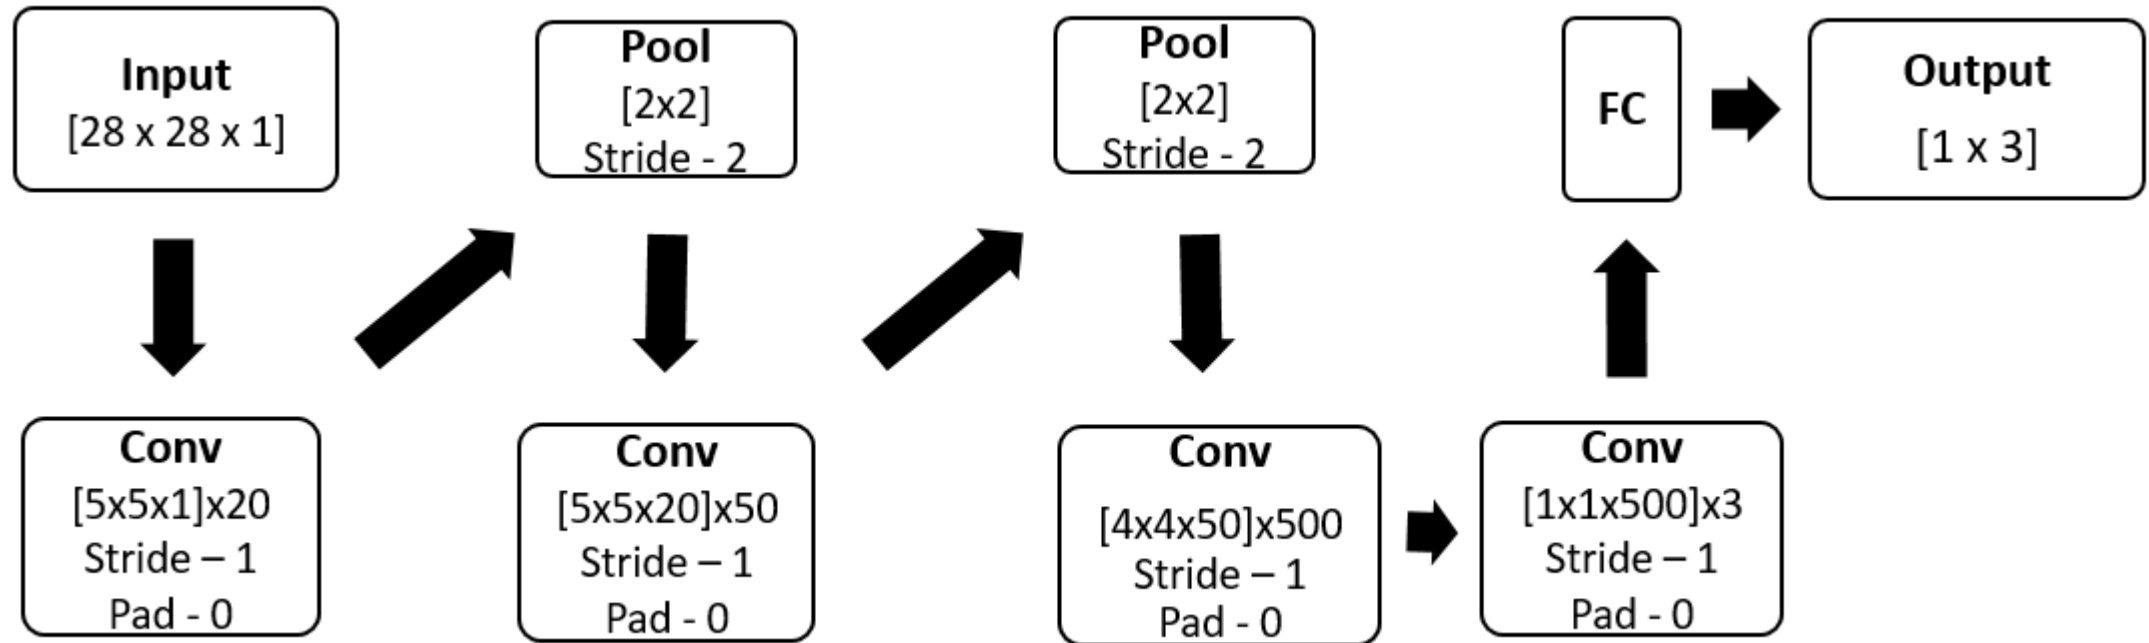


Рис. 8: Архитектура сверточной нейронной сети, использованная для реализации системы №2

График изменения значений функции ошибки для реализации системы №2





Диаграмма результатов тестирования системы



Результаты работы

1. Разработаны математические методы построения дескрипторов трехмерных поверхностей для использования в системах глубокого обучения.
2. Проведено исследование возможных архитектур СНС и на основании проведенных вычислительных экспериментов предложены две возможные архитектуры для решения задачи распознавания трехмерных моделей.
3. Создана программная реализация системы распознавания трехмерных объектов с использованием нейронных сетей глубокого обучения и открытой базы данных 3D моделей The Princeton Shape Benchmark.

Список литературы

1. Johnson A.E. Spin-Images: A Representation for 3-D Surface Matching, Ph. D. Thesis, Carnegie Mellon University, 1997, 288 p.
2. Автоматическое совмещение поверхностей в системах компьютерного зрения / А.А. Крыловецкий, И.С. Черников, С.Д. Кургалин // Математическое моделирование .— 2013 .— Т. 25, № 3. - С. 33-46.
3. Michael Neilsen. Neural Networks and Deep Learning / Michael Neilsen [Электронный ресурс].- 2017. - URL: <http://neuralnetworksanddeeplearning.com> (дата обращения 23.04.2017).

Сверточная нейронная сеть

Обучение сверточной нейронной сети

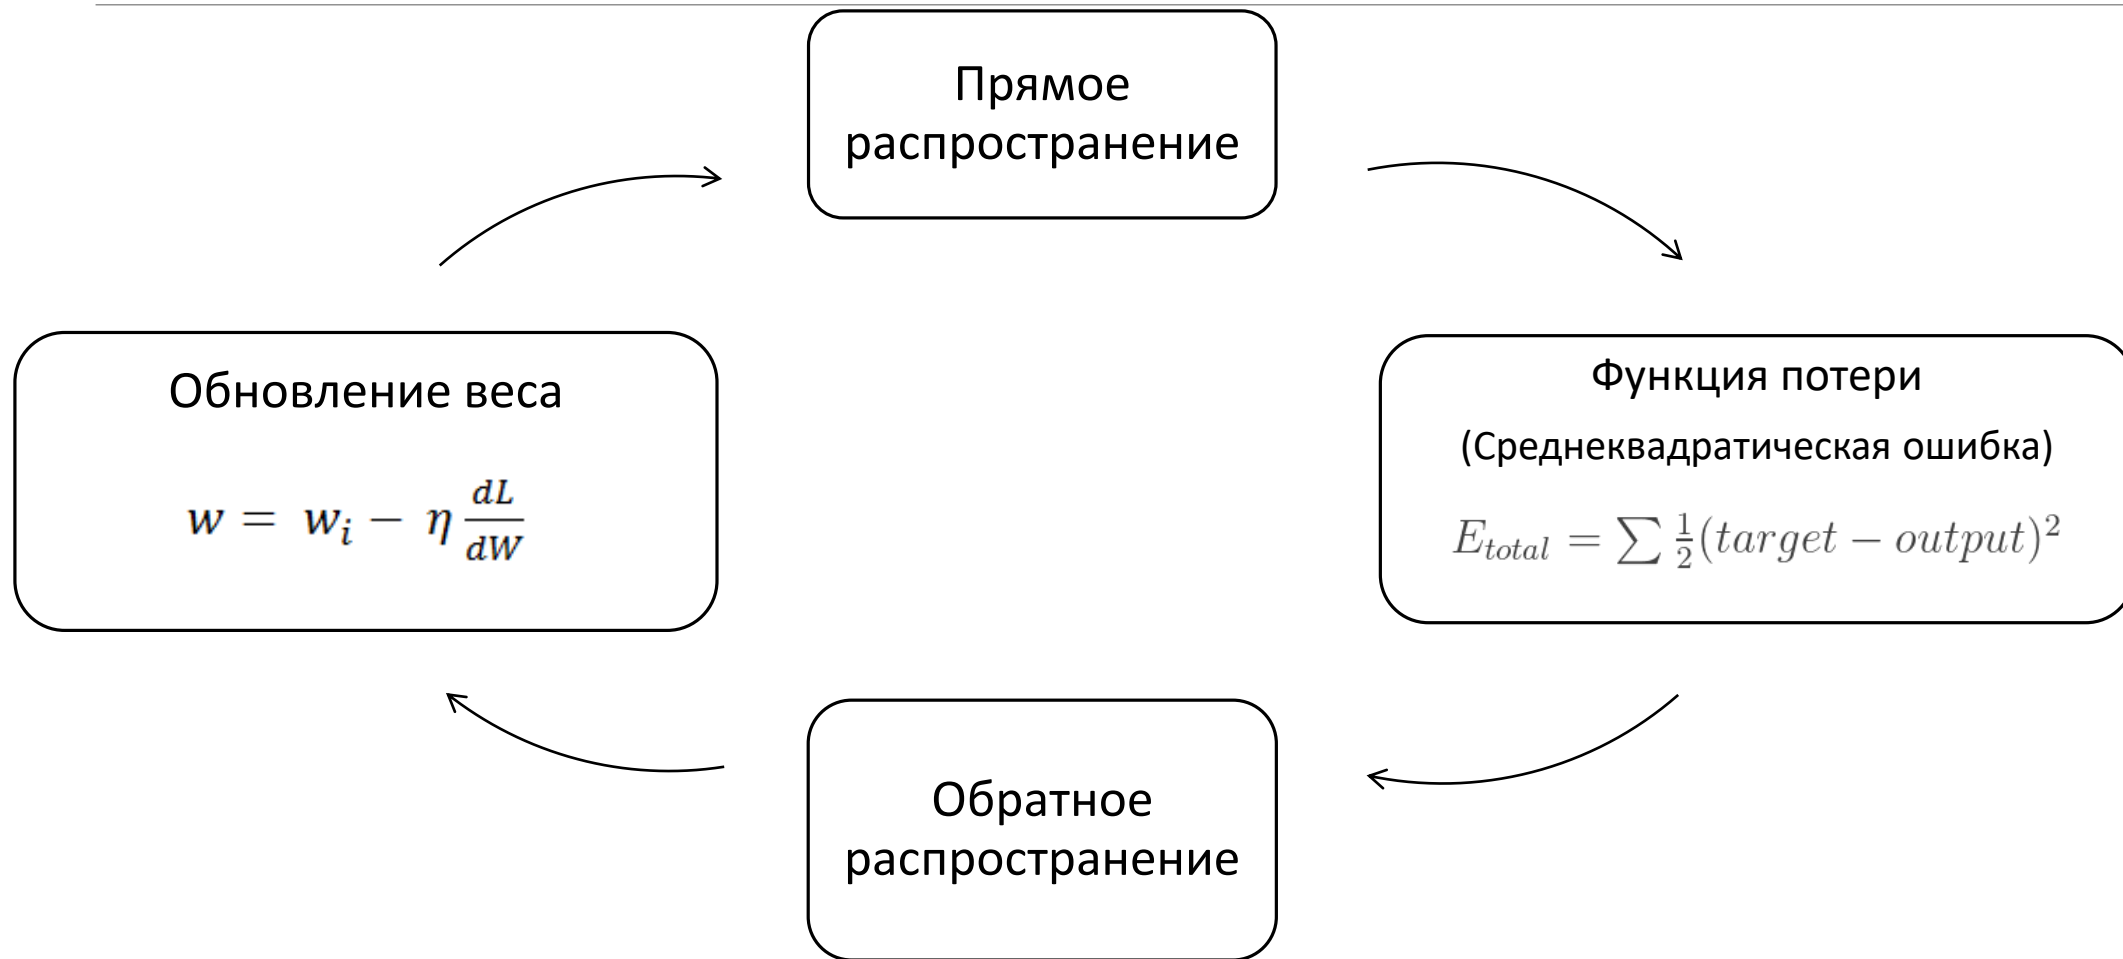



Рис. 6: Цикл метода обратного распространения ошибки

Спиновое изображение



Трехмерные объекты и графические представления их глобальных дескрипторов
для различной средней длины ребер

Функция потерь

Функция среднеквадратической ошибки

$$L(W) = \left(\sum_{p=1}^N \frac{1}{2} (D_p - O(I_p, W))^2 \right) / N$$

,где $L(W)$ — это функция ошибки для всей обучающей выборки, p - номер обучающей пары, N - количество обучающих пар, D_p — желаемый выход сети, $O(I_p, W)$ — выход сети, зависящий от p -го входа и весовых коэффициентов W .
Задача обучения так настроить веса W , чтобы они для любой обучающей пары (I_p, D_p) давали минимальную ошибку L .

Обновление веса

$$w = w_i - \eta \frac{dL(W_i)}{dW}$$

,где w_i - начальное значение регулируемого веса, $L(W_i)$ - функция ошибки, η - скорость обучения.